Формула мэтчинга отбирает резюме под вакансию на основе взвешенного пересечения навыков с использованием **TF-IDF (Term Frequency - Inverse Document Frequency).**

1. Формула расчётаTF-IDF весов

Вместо того чтобы считать все навыки одинаково важными, система оценивает «редкость» и ценность каждого навыка по всей базе резюме.

Шаг А: Расчёт веса IDF (Inverse Document Frequency)

Для каждого навыка **s** из словаря вычисляется его инверсная частота по формуле:

$$IDF(s) = \ln\left(\frac{N+1}{DF(s)+1}\right)+1$$

Где:

N - общее количество резюме в обучающей/анализируемой выборке (например, N = 1000).

DF(s) - количество резюме, в которых встретился навык s (Document Frequency).

+1 - сглаживание (Laplace smoothing), чтобы избежать деления на ноль при отсутствии навыка.

Если навык встречается часто (например, *Excel* или *Коммуникабельность*), DF(s) велико, и его вес IDF(s) стремится к единице. Если навык редкий (например, *Hadoop*, *Kubernetes*, *Basel*), DF(s) мало, а вес IDF(s) получается высоким.

Шаг Б: Расчёт итогового счета совпадения (TF-IDF Score)

Для конкретной вакансии **V** и кандидата **C**:

1. Определяется множество навыков вакансии: $\mathbf{S_V = \{S_1, S_2, \dots, S_k\}}$.
2. Определяется множество навыков кандидата: $\mathbf{S_C}$.
3. Находится пересечение (совпавшие навыки): $\mathbf{S_{match}} = S_V \cap S_C$.
4. Применяется бинарный учет частоты (**Binary TF**):

$$TF(s, C) = \begin{matrix} 1, если\ s \in S_C \\ 0, если\ s \notin S_C \end{matrix}$$

Частота повторений одного и того же термина в тексте не учитывается - факт наличия навыка в резюме фиксируется строго единицей (что исключает завышение балла из-за спама ключевыми словами).

5. Вычисляется **TF-IDF Score (%)**:

$$TF-IDF\ Score(V,C)=\frac{\sum_{s\in S_V}(\underbrace{TF(s,C)}_{\in 0,1}\times IDF(s))}{\sum_{s\in S_V} IDF(s)}\times 100\%=$$

$$=\frac{\sum_{s\in S_{match}} IDF(s)}{\sum_{s\in S_V} IDF(s)}\times 100\%$$

Вес всех совпавших навыков делится на максимально возможный вес всех требований вакансии. Чем более редкие и критичные навыки совпали, тем выше итоговый процент.

2. Приоритет выбора

После расчёта метрик для всех кандидатов система сортирует их по кортежу из трёх критериев:

$$Key(C)=(TF-IFD\ Score, S_{match}, S_C)$$

Сортировка выполняется в порядке убывания (reverse=True):

1-й приоритет: TF-IDF Score — кандидат, закрывающий наиболее ценные и редкие требования вакансии, всегда поднимается выше.

2-й приоритет: S_{match} (Количество совпавших навыков) — если у двух кандидатов проценты совпали (до миллионных долей), выше встаёт тот, у кого совпало большее абсолютное число навыков.

3-й приоритет: S_C (Общее число навыков кандидата) — если равны и процент, и число совпадений, приоритет отдаётся кандидату с более широким кругозором и стеком.

3. Сравнение с базовой метрикой (Base Score)

Для оценки эффективности в коде также рассчитывается базовый метрический скор без учёта весов:

$$Base\ Score\left(V,C\right)=\frac{S_{match}}{S_V}\times 100\,\%$$

Base Score показывает простое пропорциональное покрытие (например, кандидат закрыл 2 из 3 навыков = 66.6%).

TF-IDF Score отражает реальную сложность найма: кандидат, знающий редкий ключевой стек, получит значительно более высокий балл, чем кандидат, закрывший то же количество простых/общих навыков.